



## Expresiones regulares

reg[ular]  
expr[essio]n

Teoría Computacional  
Prof. Luis Enrique Hernández Olvera



## Contenido

- Repaso de definiciones.
- Lenguajes Regulares
- Expresiones regulares
- Operadores de las expresiones regulares

Teoría Computacional  
Prof. Luis Enrique Hernández Olvera

2



## Repasando definiciones

- Un conjunto no vacío y finito de símbolos se conoce como alfabeto ( $\Sigma$ ).
- Una secuencia finita de símbolos de un determinado alfabeto se conoce como palabra sobre dicho alfabeto (a-z).
- Cada símbolo de un alfabeto es una cadena sobre dicho alfabeto.
- La cadena vacía, la cual se denota por el símbolo  $\epsilon$ , es una palabra sobre cualquier alfabeto.

Teoría Computacional  
Prof. Luis Enrique Hernández Olvera

3



- Un lenguaje es un conjunto de palabras. Por lo tanto el conjunto  $\{1,12,123,1234,12345\}$  es un lenguaje sobre el alfabeto compuesto por dígitos.
- Si  $\Sigma$  es un alfabeto, también es un lenguaje (El formado por todas las cadenas con un único símbolo).

Teoría Computacional  
Prof. Luis Enrique Hernández Olvera

4



- Dado que un lenguaje es un conjunto de cadenas, se puede tener el lenguaje compuesto por ninguna cadena (El lenguaje vacío).
- El lenguaje vacío se denota de la misma forma que el conjunto vacío  $\emptyset$ .

Teoría Computacional  
Prof. Luis Enrique Hernández Olvera

5



- $\emptyset$ , el lenguaje vacío, es un lenguaje de cualquier alfabeto.
- $\{\epsilon\}$ , el lenguaje que consta sólo de la cadena vacía, también es un lenguaje de cualquier alfabeto.
- $\emptyset \neq \{\epsilon\}$ ; el primero no contiene ninguna cadena y el segundo sólo tiene una cadena.

Teoría Computacional  
Prof. Luis Enrique Hernández Olvera

6



- El conjunto de todas las cadenas de un alfabeto  $\Sigma$ , se conoce como **cerradura de  $\Sigma$**  o **lenguaje universal de  $\Sigma$**  y se denota por  $\Sigma^*$ .

- Por ejemplo, si se tiene el alfabeto  $\Sigma=\{1\}$ , entonces:

$$\Sigma^*=\{\epsilon, 1, 11, 111, 1111, 11111, \dots\}$$



- El conjunto de todas las cadenas de un alfabeto  $\Sigma$  se designa mediante  $\Sigma^*$ .

$$\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \Sigma^2 \cup \dots$$

- El conjunto de cadenas no vacías del alfabeto  $\Sigma$  se designa como **cerradura positiva  $\Sigma^+$** .
- Por lo tanto las dos equivalencias son:
- $\Sigma^+ = \Sigma^1 \cup \Sigma^2 \cup \Sigma^3 \cup \dots$
- $\Sigma^* = \Sigma^+ \cup \{\epsilon\}$ .

Recuerda  
 $\Sigma^0 = \{\epsilon\}$



## Lenguajes Regulares

- Los lenguajes regulares sobre un alfabeto pueden ser usados para especificar la construcción de analizadores léxicos (programas que analizan un texto y extraen los lexemas o unidades léxicas) que hay en el mismo.
- Para un alfabeto  $\Sigma$  dado, los lenguajes regulares sobre  $\Sigma$  constituyen el menor conjunto de lenguajes sobre  $\Sigma$  que es cerrado con respecto a las operaciones de concatenación, la cerradura de Kleene y la unión de lenguajes y además contienen el lenguaje vacío  $\emptyset$  y los lenguajes unitarios  $\{a\}$  para  $a \in \Sigma$ .



## Lenguajes Regulares

- Los lenguajes más sencillos que formalmente se consideran son los **lenguajes regulares**.
- Un lenguaje regular se puede generar a partir de lenguajes básicos, con la aplicación de las operaciones de **unión**, **concatenación** y **cerradura de Kleene** un número finito de veces.



## Lenguajes Regulares

- Los lenguajes regulares se llaman así porque sus palabras contienen "**regularidades**" o repeticiones de los mismos componentes.
- Por ejemplo:
  - $L_1 = \{ab, abab, ababab, abababab, \dots\}$
- En este ejemplo se aprecia que las palabras de  $L_1$  son simplemente repeticiones de "ab" cualquier número de veces. Aquí la "regularidad" consiste en que las palabras contienen "ab" algún número de veces.



- Un **lenguaje regular** es un tipo de **lenguaje formal** que satisface las siguientes propiedades:

- Puede ser reconocido por:**
  - Un autómata finito determinista
  - Un autómata finito no determinista
  - Un autómata de pila
  - Un autómata finito alterno
  - Una máquina de Turing de solo lectura
- Es generado por:**
  - Una gramática regular
  - Una gramática de prefijos

- Es descrito por:**
  - Una expresión regular



## Definición formal de lenguaje regular

- Sea  $\Sigma$  un alfabeto. El conjunto de los lenguajes regulares sobre  $\Sigma$  se define recursivamente como sigue:
  - El lenguaje vacío  $\emptyset$  es un lenguaje regular.
  - El lenguaje cadena vacía  $\{\epsilon\}$  es un lenguaje regular.
  - Para todo  $a \in \Sigma$ ,  $\{a\}$  es un lenguaje regular.
  - Si  $A$  y  $B$  son lenguajes regulares, entonces  $A \cup B$ ,  $A \cdot B$  y  $A^*$  son lenguajes regulares.



Un lenguaje  $L$  es regular si y solo si se cumple al menos una de las condiciones siguientes:

- $L$  es finito (Estos son lenguajes obviamente regulares y uno podría crear expresiones regulares que serían la unión de todas las palabras del lenguaje que definirían dicho lenguaje.)
- $L$  es la unión o la concatenación de otros lenguajes regulares  $R_1$  y  $R_2$ ,  $L = R_1 \cup R_2$  o  $L = R_1 R_2$  respectivamente
- $L$  es la cerradura de Kleene de algún lenguaje regular,  $L = R^*$



## Ejemplo

Dado  $\Sigma = \{a, b\}$ , las siguientes afirmaciones son ciertas:

- $\emptyset$  y  $\{\epsilon\}$  son lenguajes regulares
- $\{a\}$  y  $\{b\}$  son lenguajes regulares
- $\{a, b\}$  es un lenguaje regular
- $\{ab\}$  es un lenguaje regular
- $\{a, ab, b\}$  es un lenguaje regular
- $\{a^i \mid i \geq 0\}$  es un lenguaje regular
- $\{a^i b^j \mid i \geq 0 \text{ y } j \geq 0\}$  es un lenguaje regular
- $\{(ab)^i \mid i \geq 0\}$  es un lenguaje regular



Dado  $\Sigma = \{a, b, c\}$ , ¿El lenguaje de todas las cadenas sobre el  $\Sigma$  que no contiene ninguna subcadena  $ac$  es regular?

- $\{c\}$ ,  $\{a\}$ ,  $\{b\}$  son L.R. (3)
- $\{c\}^*$  es un L.R. (4, \*)
- $\{b\}\{c\}^*$  es un L.R. (4, ·)
- $\{a\} \cup \{b\}\{c\}^*$  es un L.R. (4,  $\cup$ )
- $\{(\{a\} \cup \{b\}\{c\}^*)^*\}$  es un L.R. (4, \*)
- $\{c\}^* (\{a\} \cup \{b\}\{c\}^*)^*$  es un L.R. (4, ·)



## Expresiones regulares

- Una **expresión regular** es una forma abreviada de representar cadenas de caracteres que se ajustan a un determinado patrón. Al **conjunto de cadenas representado por la expresión  $r$**  se lo llama *lenguaje generado por la expresión regular  $r$*  y se escribe  $L(r)$ .
- Una expresión regular se define sobre un alfabeto  $\Sigma$  y es una **cadena formada por caracteres** de dicho alfabeto y por una serie de **operadores**.



- Las expresiones regulares sirven como lenguaje de entrada de muchos sistemas que procesan cadenas por ejemplo generadores de analizadores léxicos, como Lex o Flex.
- Un generador de analizadores léxicos acepta descripciones de las formas de las unidades lógicas, que son principalmente expresiones regulares, y produce un AFD que reconoce qué unidad lógica aparece a continuación en la entrada.





Si  $A$  es un alfabeto, una expresión regular sobre este alfabeto se define de la siguiente forma:

- $\emptyset$  es una expresión regular que denota el lenguaje vacío.
- $\epsilon$  es una expresión regular que denota el lenguaje  $\{\epsilon\}$
- Si  $a \in A$ ,  $a$  es una expresión regular que denota el lenguaje  $\{a\}$
- Si  $r$  y  $s$  son expresiones regulares, entonces  $r \cup s$ ,  $r \cdot s$  y  $r^*$  también lo son.



## Operadores de las expresiones regulares

- Unión:  $(r+s)$  es una expresión regular que denota el lenguaje  $R \cup S$ .
- Concatenación:  $(rs)$  es una expresión regular que denota el lenguaje  $R \cdot S$
- Clausura:  $r^*$  es una expresión regular que denota el lenguaje  $R^*$ .



## Ejemplos

$A=\{0,1\}$

- $00$  El conjunto  $\{00\}$
- $01^*$  Conjunto de palabras que empiezan por 0 y después tienen una sucesión de unos.
- $(1+10)^*$  Conjunto de palabras en las que los ceros están precedidos siempre por unos.
- $(0+1)^*011$  Conjunto de palabras que terminan en 011



## Ejemplos

$A=\{0,1\}$

- $0^*1^*$  Conjunto de palabras formadas por una sucesión de ceros seguida de una sucesión de unos. Ambas sucesiones pueden ser vacías.
- $00^*11^*$  Conjunto de palabras formadas por una sucesión de ceros seguida de una sucesión de unos. Ninguna de las sucesiones puede ser vacía.

A  $r^*r$  se le denota como  $r^+$ . Por lo que en la última expresión regular quedaría como  $0^+1^+$



## Ejemplos

$\Sigma = \{a, b\}$

- $a|b$  denota el lenguaje  $L(a|b)=\{a, b\}$ .
- $(a|b)(a|b)$  denota a  $L((a|b)(a|b))$ , el lenguaje de todas las cadenas de longitud dos sobre el alfabeto  $\Sigma$ .
- $(a|b)(a|b) = aa|ab|ba|bb$
- $L(a^*) = \{\lambda, a, aa, aaa, \dots\}$ , todas las cadenas de cero o más  $a$ 's.



## Ejemplos

$(a)|((b)^*(c)) = a|b^*c$

– Descripción:

- Conjunto de cadenas que son una sola  $a$  o ninguna o más  $b$ 's seguidas por una  $c$ .

– Algunas cadenas del lenguaje:

- $L(a|b^*c) = \{a, c, bc, bbcc, bbbcc, \dots\}$



- Existen muchas equivalencias con respecto a expresiones regulares basadas en las correspondientes igualdades de lenguajes. Se resumen en el siguiente teorema.
- Sean  $r, s$  y  $t$  expresiones regulares sobre el mismo alfabeto  $\Sigma$ . Entonces:



1.  $r + s = s + r$
2.  $r + \emptyset = r = \emptyset + r$
3.  $r + r = r$
4.  $(r + s) + t = r + (s + t)$
5.  $r\epsilon = \epsilon r = r$
6.  $r\emptyset = \emptyset r = \emptyset$
7.  $(rs)t = r(st)$
8.  $r(s+t) = rs+rt$ , y  $(r+s)t = rt+st$
9.  $r^* = r^*r^* = r^*r^*(\epsilon+r)^* = r^*(r+\epsilon)^* = (r+\epsilon)r^* = \epsilon+rr^*$
10.  $(r+s)^* = (r^*+s^*)^* = (r^*s^*)^* = (r^*s)^*r^* = r^*(sr^*)^*$
11.  $r(sr)^* = (rs)^*r$
12.  $(r^*s)^* = \epsilon + (r+s)^*s$
13.  $(rs^*)^* = \epsilon + r(r+s)^*$
14.  $s(r+\epsilon)^*(r+\epsilon)+s = sr^*$
15.  $rr^* = r^*r$



## Ejercicios

- Describa los lenguajes generados por las siguientes expresiones regulares y enumere al menos 7 cadenas de cada lenguaje.  $\Sigma = \{a, b, c, d, e, \dots, z\}$
- $(ab)|(cz)|d^*$
- $a+b+c \mid (b+d)z$
- $(abc)^*z$
- $(a|b)^*|a$
- $(ab)^*(bc)^+$